Handbuch: Server-Architektur, Kostenkalkulation & Voice-AI-Integration (Anfänger-Edition)

Projekt: KI-Telefonassistent & Smart-Routing (Storm GmbH)
Ziel: Rechtssicheres (DSGVO), wartungsarmes und vor Kostenexplosionen geschütztes Hosting sowie die nahtlose Einbindung von Sprach-KI (ElevenLabs, Retell/Vapi) und Telefonie.

---

1. Architektur-Entscheidung: Eigener Server vs. Kunden-Server

Empfohlenes Geschäftsmodell: Managed SaaS (Zentrales Hosting auf deinem eigenen Server mit Kunden-Login)

Die gesamte Anwendungslogik, Datenbank und KI-Orchestrierung läuft auf **deiner eigenen Server-Infrastruktur**. Die Storm GmbH erhält lediglich einen geschützten Web-Zugang (z. B. `https://storm.deine-ki-agentur.de`) sowie die automatische Synchronisation in ihr bestehendes Microsoft Outlook.

Warum du das System nicht auf dem Server des Kunden installieren solltest:

1. **Schutz deines geistigen Eigentums (IP):** Deine System-Prompts, Routing-Logiken und API-Verknüpfungen sind dein Geschäftsgeheimnis. Liegt der Quellcode ungeschützt beim Kunden, machst du dich langfristig ersetzbar.
2. **Skalierbarkeit & Wartung:** Wenn du zukünftig 10 oder 20 Betriebe betreust, kannst du Updates, Sicherheits-Patches und neue Features zentral auf deinem Server einspielen, statt dich auf 20 fremden Kundensystemen einloggen zu müssen.
3. **Null IT-Aufwand für den Kunden:** Mittelständische Betriebe wie die Storm GmbH möchten keine eigenen Server oder Datenbanken warten. Sie kaufen eine schlüsselfertige Lösung, die einfach funktioniert.

Hinweis zur Schnittstelle: Lediglich das Microsoft-365-Konto (Outlook) verbleibt natürlich bei der Storm GmbH. Dein Server kommuniziert verschlüsselt über die offizielle Microsoft Graph API mit deren Postfächern und Kalendern.

---

2. Server-Auswahl & Schutz vor Kostenexplosionen

Bei klassischen Serverless-Plattformen (wie Vercel, Netlify oder externen Cloud-Datenbanken mit nutzungsbasierter Abrechnung) besteht bei fehlerhaften Skripten oder Bot-Angriffen (DDoS) das Risiko unvorhersehbarer Rechnungen.

Die optimale Lösung: **Ein eigener kleiner Virtual Private Server (VPS) mit „Coolify“**

- **100 % Kostendeckel (Fixpreis):** Ein kleiner virtueller Server kostet **fest ca. 5,00 € bis 10,00 € brutto pro Monat**. Es gibt keine versteckten Gebühren pro Seitenaufruf oder Datenbankabfrage.
- **DSGVO-Konformität:** Rechenzentren in Deutschland sorgen für Rechtssicherheit im Verkaufsgespräch.
- **Komfort wie bei Netlify/Vercel durch „Coolify“:** Auf dem Server wird das kostenlose Open-Source-Tool **Coolify** installiert. Damit erhältst du eine moderne Weboberfläche, über die du sowohl deine **Next.js-Anwendung** als auch deine eigene **PostgreSQL-Datenbank** per 1-Klick direkt aus GitHub heraus inkl. kostenlosem SSL-Zertifikat (`https://`) betreibst.

---

3. Schritt-für-Schritt-Anleitung: Server mieten & Coolify installieren (Für absolute Anfänger)

Da Hetzner im ersten Moment technisch wirken kann, schauen wir uns beide Wege an. **IONOS ist für absolute Einsteiger oft optisch etwas übersichtlicher**, Hetzner ist technisch minimal günstiger. Du kannst für dieses Projekt exakt denselben Weg wählen, der dir leichter fällt.

Weg A: Server bei IONOS mieten & einrichten (Besonders einsteigerfreundlich)

1. Gehe auf **ionos.de** und wähle im Menü den Bereich **Server & Cloud** → **VPS** (Virtual Private Server).
2. Wähle das kleinste, vollkommen ausreichende Modell (z. B. **VPS Linux XS** oder **S** mit ca. 2 bis 4 GB RAM).
3. Klicke auf Bestellen und richte deinen Account ein.
4. Nach wenigen Minuten ist dein Server im IONOS Cloud-Panel einsatzbereit. Du erhältst dort deine **IP-Adresse** (z. B. `192.168.1.50`) und ein initiales Root-Passwort.
5. **Betriebssystem wählen:** Installiere im IONOS Panel als Betriebssystem **Ubuntu 22.04 LTS oder 24.04 LTS**.
6. **Coolify mit einem Klick installieren:**

- Öffne auf deinem Computer das Programm **Terminal** (Mac) oder **PuTTY / Eingabeaufforderung** (Windows).
- Tippe folgenden Befehl ein (ersetze `DEINE-SERVER-IP` durch die IP von IONOS) und drücke Enter:

```
Shell
ssh root@DEINE-SERVER-IP
```

- Gib das Passwort ein, das dir IONOS geschickt hat.
- Kopiere nun diesen offiziellen Installationsbefehl von Coolify und füge ihn im Terminal ein:

```
Shell
curl -fsSL https://cdn.coollabs.io/coolify/install.sh | bash
```

- Warte ca. 3–5 Minuten, bis die Installation durchgelaufen ist. Am Ende zeigt dir das Terminal eine Web-Adresse an (z. B. `http://DEINE-SERVER-IP:8000`).

Weg B: Server bei Hetzner Cloud mieten & einrichten

1. Registriere dich unter **hetzner.com/de/cloud/** und lege ein neues Projekt an.
2. Klicke auf **Server hinzufügen**:
   - **Standort:** Nürnberg oder Falkenstein (Deutschland).
   - **Image:** Wechsle auf den Reiter **Apps** und wähle **Coolify** (hier installiert Hetzner das komplette Coolify-Verwaltungssystem vollautomatisch vor, sodass du kein Terminal bedienen musst!).
   - **Typ: CX22** oder **CPX21** (4–8 GB RAM).
3. Klicke auf **Kostenpflichtig erstellen**. Du erhältst per E-Mail die IP-Adresse deines Servers.
4. **Coolify aufrufen:** Rufe im Browser direkt `http://IP-DEINES-HETZNER-SERVERS:8000` auf. Beim ersten Aufruf wirst du aufgefordert, dein Admin-Konto anzulegen.

---

4. Datenbank & Web-App über Coolify veröffentlichen (Dauer: 10 Min.)

1. **Domain verbinden:** Registriere eine eigene Agentur-Domain (z. B. `deine-ki-agentur.de`) und erstelle in den DNS-Einstellungen einen **A-Record** für

die Subdomain `storm.deine-ki-agentur.de`, die auf die öffentliche IP-Adresse deines Servers zeigt.
2. **Datenbank anlegen:** Klicke in Coolify auf **+ New Resource** → **Database** → **PostgreSQL**. Kopiere dir die interne `DATABASE_URL`.
3. **Code verbinden:** Lade dein Projekt in ein privates **GitHub-Repository** hoch.
4. Klicke in Coolify auf **+ New Resource** → **Public / Private Repository (GitHub)** und wähle dein Projekt aus.
5. Trage unter **Domains** deine Adresse `https://storm.deine-ki-agentur.de` ein (Coolify erstellt automatisch das kostenlose Let's-Encrypt-SSL-Zertifikat).
6. Hinterlege unter **Environment Variables** deine Variablen (`DATABASE_URL`, `MICROSOFT_TENANT_ID`, `MICROSOFT_CLIENT_ID`, `MICROSOFT_CLIENT_SECRET`).
7. Klicke oben rechts auf **Deploy**. Nach ca. 2 Minuten sind dein Dashboard und dein Webhook live unter `https://storm.deine-ki-agentur.de` erreichbar.

---

5. Exakte Kostenkalkulation: Stimmen-KI, Telefonie & LLM

Bei einem KI-Telefonassistenten fallen die variablen Kosten **pro gesprochener Gesprächsminute** an.

5.1 Aufschlüsselung der Minutenpreise

Komponente	Empfohlener Anbieter	Aufgabe im System	Kosten pro Minute (ca.)
1. Voice-Orchestrator	**Retell AI** oder **Vapi.ai**	Verbindet Telefonleitung, Stimme und KI; steuert Sprecherwechsel & Unterbrechungen	ca. **0,050 €**
2. Sprachausgabe (TTS)	**ElevenLabs** *(Turbo / Flash v2.5)*	Erzeugt die natürliche, empathische deutsche Stimme ohne Roboter-Akzent	ca. **0,040 € – 0,060 €**
3. Spracherkennung (STT)	**Deepgram** *(Nova-2)*	Wandelt das Gesprochene des Anrufers in Echtzeit in Text um	ca. **0,010 €**
4. Sprachmodell (LLM)	**OpenAI GPT-4o-mini**	Versteht das Anliegen, kategorisiert den Fall und ruft die Outlook-Tools auf	ca. **0,005 €**
5. Telefonie (VoIP/SIP)	**Twilio** oder **sipgate**	Stellt die deutsche Ortsrufnummer und die Sprachverbindung bereit	ca. **0,010 € – 0,015 €**

Komponente	Empfohlener Anbieter	Aufgabe im System	Kosten pro Minute (ca.)
GESAMTSUMME	**Komplettbetrieb**	**All-in Selbstkostenpreis pro Gesprächsminute**	**ca. 0,12 € – 0,14 € / Min.**

5.2 Monatskalkulation am Beispiel der Storm GmbH

- **Anrufvolumen:** 300 durch die KI angenommene Anrufe pro Monat (ca. 10 Anrufe täglich).
- **Durchschnittliche Gesprächsdauer:** 2,5 Minuten.
- **Gesamtminuten pro Monat:** $300 \times 2{,}5 \text{ Min.} = \mathbf{750 \text{ Minuten}}$.

Deine monatlichen Selbstkosten:

1. **Variable KI- & Telefoniekosten:** $750 \text{ Min.} \times 0{,}13\text{ €} = \mathbf{97{,}50\text{ €}}$
2. **Server (IONOS / Hetzner Cloud inkl. Datenbank):** $\mathbf{7{,}00\text{ €}}$
3. **Deutsche Rufnummer (Grundgebühr Twilio):** $\mathbf{1{,}15\text{ €}}$
- **Gesamtkosten für dich: ca. 105,65 € netto / Monat**

Deine Preisgestaltung gegenüber dem Kunden (Beispiel):

- **Einmalige Einrichtungsgebühr (Setup): 1.800,00 € netto**
- **Monatliche Betreuungspauschale (inkl. 500 Freiminuten): 450,00 € netto / Monat**
- **Zusatzminuten ab der 501. Minute: 0,29 € netto / Minute**
- **Dein monatlicher Rohgewinn (Marge):** $\mathbf{416{,}85\text{ € Gewinn pro Monat (bei nur einem Kunden)}}$.

5.3 Sicherheitsmechanismen gegen Kostenexplosionen

1. **Vertragliches Kontingent-Modell:** Inklusiv-Minuten abfangen.
2. **Maximale Gesprächsdauer:** Hard Limit von **5 Minuten pro Anruf**.
3. **Hard-Limits im API-Dashboard:** Monatliches Ausgabenlimit (*Monthly Spend Limit*, z. B. 150 €) setzen.
4. **Rate-Limiting auf dem Webhook:** Nur autorisierte Anfragen von Retell/Vapi zulassen.

---

6. Stimm-KI & Telefonie anbinden (Zusammenfassung)

1. **Retell AI / Vapi.ai Account erstellen:** Wähle als Stimm-Anbieter **ElevenLabs** (Modell *Eleven Turbo v2.5* oder *Flash v2.5*) für minimale Verzögerung auf Deutsch.
2. **System-Prompt hinterlegen:** Den strukturierten Prompt für die Storm GmbH eintragen.
3. **Webhook verknüpfen:** Trage als Ziel-URL deine Live-Adresse ein: `https://storm.deine-ki-agentur.de/api/voice/webhook`.
4. **Deutsche Rufnummer aufschalten:** Kaufe eine Nummer bei Twilio und verbinde sie mit deinem Agenten.
5. **Weiterleitung einrichten:** Die Storm GmbH leitet Anrufe bei Besetzt oder nach 15 Sekunden Klingeln an deine neue KI-Nummer weiter.